Détection paire-à-paire de réutilisation musicale dans des masters audio

Note d'hypothèse, modèle de mesure et protocole de falsification

Projet Veridis-tille

Document de travail — 18 octobre 2026

POC EXPLORATOIRE | VERSION 2 | DÉCISION ASSISTÉE

Résumé

Ce travail étudie une question technique limitée : **étant donnés deux enregistrements audio finis, peut-on détecter et localiser une réutilisation musicale entre eux ?** Le système ne recherche pas un titre dans un catalogue et ne prononce pas un plagiat au sens juridique. Il calcule des indices de similarité suffisamment précis pour aider un expert à examiner une paire proposée : un morceau de référence et un morceau suspect.

L'intuition initiale doit être formulée avec prudence. Un master est le résultat observable d'un mixage de sources musicales latentes. Une séparation de sources telle que Spleeter ne restitue pas les pistes de studio : elle en produit des **estimations**, susceptibles de contenir des fuites et des artefacts. De même, une transcription automatique fournit des événements de notes estimés, et non une partition vraie. La chaîne « séparation puis pitch » est donc une méthode candidate. Son utilité doit être démontrée par comparaison avec une méthode qui travaille directement sur le mix complet.

L'hypothèse principale est falsifiable : si deux enregistrements partagent un passage musical issu d'une même matière source, des représentations robustes au timbre, à la transposition et à des variations modérées de tempo devraient produire une similarité locale plus élevée que pour des paires indépendantes, y compris des négatifs musicalement proches. Une deuxième hypothèse teste si la séparation en sources améliore réellement cette discrimination. Le protocole exige des familles de chansons disjointes entre apprentissage, validation et test, des négatifs difficiles, des ablations et un test final conservé intact.

1. Objet scientifique et limites de l'inférence

1.1 Ce qui est observé

Le fichier distribué est un signal stéréo final, noté $x(t)$. On peut le représenter schématiquement comme une combinaison de sources latentes $s_1(t), \ldots, s_k(t)$, transformées par le mixage, les effets et le mastering :

$$x(t) = M(s_1(t), \ldots, s_k(t)) + \varepsilon(t)$$

La fonction M n'est ni connue ni, en général, inversible. Plusieurs ensembles de sources peuvent expliquer le même mix. Une séparation calcule donc $\hat{s}_k(t)$, une estimation conditionnée par son modèle et ses données d'entraînement. Elle ne permet pas d'affirmer que $\hat{s}_k = s_k$.

1.2 Ce que la méthode peut conclure

Pour deux fichiers A et B, la sortie recherchée est :

- un score de similarité paire-à-paire ;
- une décision au seuil, calibrée sur des données distinctes ;
- un ou plusieurs couples d'intervalles temporels qui expliquent le score ;
- les transformations estimées, par exemple transposition et rapport de tempo.

Cette sortie constitue un **indice technique de similarité musicale**. Le mot « plagiat » désigne ici l'étiquette du jeu de données. Une qualification juridique demande d'autres éléments : originalité du matériau, accès à l'œuvre, importance qualitative de l'emprunt et contexte de création.

1.3 Ce que l'on sait sur les données génératives

Suno déclare entraîner ses modèles sur des dizaines de millions de fichiers audio musicaux publics et leurs métadonnées, ainsi que sur certaines données post-entraînement. Cette publication établit l'usage de fichiers audio, mais elle ne documente ni leur statut exact de master, ni l'éventuelle présence de stems, ni l'architecture et les représentations internes du modèle [1].

L'entraînement sur des fichiers audio complets **n'implique pas** qu'une sortie générée contienne une piste source récupérable. Un modèle peut apprendre des régularités générales, mémoriser certains fragments, les transformer, ou combiner plusieurs influences. La persistance d'un motif identifiable dans une sortie est précisément la question empirique ; elle ne doit pas servir de prémisse à la démonstration.

2. Hypothèses falsifiables

H_0 — hypothèse nulle. À difficulté musicale comparable, les scores des paires liées et indépendantes suivent la même distribution. Les performances observées sur le petit corpus proviennent du hasard, d'artefacts de génération, d'un réglage excessif ou de variables parasites.

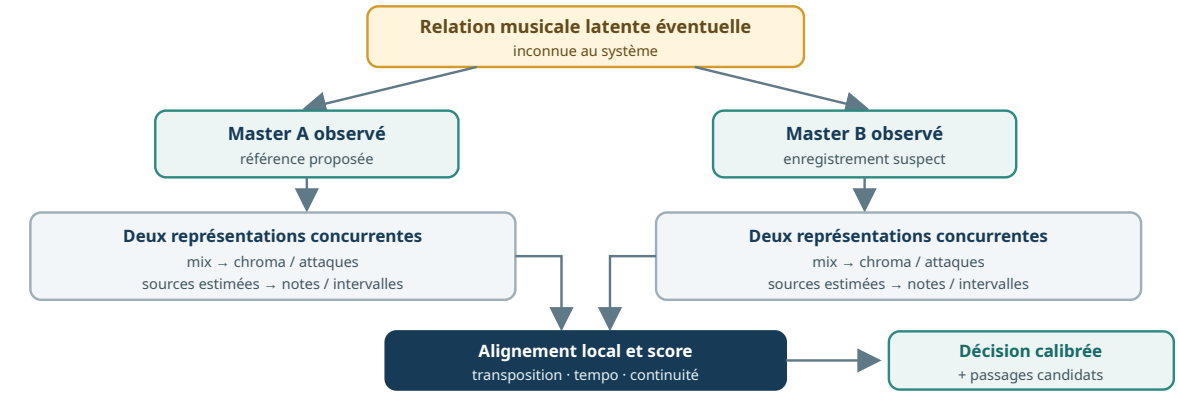
H_1 — persistance d'un motif local. Une paire liée contient au moins un passage dont la structure de hauteurs et/ou d'attaques reste plus similaire que celle de paires indépendantes, après compensation d'une transposition et d'une variation modérée de tempo.

H_2 — valeur ajoutée de la séparation. Les représentations calculées sur des sources estimées améliorent la discrimination hors échantillon par rapport aux mêmes familles d'indices calculées sur le mix complet. Si elles n'apportent aucun gain stable, la séparation n'est pas justifiée pour ce POC.

H_3 — complémentarité. Les erreurs de la transcription MIDI et des descripteurs audio continus ne sont pas totalement corrélées. Leur fusion, réglée sans voir le test, améliore le compromis précision–rappel sans accroître de manière disproportionnée les faux positifs.

Ces hypothèses ne prétendent pas déduire le mécanisme interne du générateur. Elles testent uniquement une relation mesurable entre deux signaux de sortie.

3. Modèle de mesure



Chaque transformation peut supprimer de l'information ou créer un artefact : elle doit être évaluée par ablation.

3.1 Représentations candidates

Branche	Mesure	Invariance recherchée	Risque principal
Mix complet	chroma à 12 classes, énergie d'attaque	timbre, octave, transposition	accords banals et tonalité commune
Sources estimées	activité de notes, vélocité, intervalles	timbre, gain, transposition	erreurs Spleeter puis Basic Pitch
Alignement temporel	fenêtres locales, rapports de tempo	décalage et tempo modéré	maximum fort obtenu par hasard
Fusion	combinaison de scores complémentaires	type de transformation inconnu	surapprentissage des seuils

Spleeter fournit des modèles pré-entraînés de séparation à deux, quatre ou cinq stems. Son article décrit des masques spectraux estimés par U-Net et propose la séparation comme prétraitement possible pour la transcription, l'extraction de mélodie et la détection de reprises [2]. Basic Pitch est un modèle de transcription polyphonique, indépendant de l'instrument, qui estime notamment les attaques, le multipitch et les activations de notes [3]. Ces travaux justifient la faisabilité technique des mesures ; ils ne prouvent pas H_2 sur notre corpus.

Le chroma regroupe l'énergie spectrale dans les douze classes de hauteur en repliant les octaves. Cette représentation a déjà été employée pour comparer des versions d'un même morceau malgré des différences d'instrumentation et de tonalité, avec alignement temporel et examen des douze transpositions [4]. Elle constitue donc un contrôle direct sur le mix complet.

3.2 Variable cible

L'unité statistique est la **paire de morceaux**, et l'unité d'indépendance est la **famille de chanson**. Une paire positive relie un original documenté à une version dérivée. Une paire négative relie deux familles indépendantes. Les évaluations répétées d'une même paire dans plusieurs folds ne sont pas huit nouveaux morceaux : elles mesurent la stabilité du réglage.

4. Protocole expérimental

4.1 Constitution des données

1. Définir les paires et leur provenance avant le calcul des scores.
2. Grouper un original et toutes ses variantes dans une même famille.
3. Séparer les familles entre apprentissage, validation et test ; aucun fichier audio ne doit apparaître dans deux ensembles.
4. Inclure des négatifs faciles et des **négatifs difficiles** partageant genre, tonalité, tempo, progression harmonique, époque ou timbres.
5. Documenter, lorsque c'est possible, les intervalles réellement repris afin d'évaluer la localisation, pas seulement la décision globale.

Avec seulement huit familles, le protocole actuel écarte deux familles à la fois et règle les paramètres sur les six restantes. Il convient à l'exploration et à l'élimination d'idées faibles. Il ne remplace pas un jeu de test indépendant.

4.2 Comparaisons nécessaires

Expérience	Question isolée	Comparaison décisive
A — mix complet	existe-t-il un signal sans séparation ?	chroma du mix contre H_0
B — ablation Spleeter	la séparation apporte-t-elle de l'information ?	mix seul contre stems seuls, mêmes folds

Expérience	Question isolée	Comparaison décisive
C — ablation de transcription	le MIDI aide-t-il malgré ses erreurs ?	chroma de stems contre notes Basic Pitch
D — invariances	quel changement est réellement toléré ?	sans/avec transposition et rapports de tempo
E — fusion	les indices sont-ils complémentaires ?	meilleur indice seul contre combinaison réglée en interne
F — robustesse	le score capte-t-il autre chose que le style ?	négatifs difficiles et générateurs nouveaux

Les paramètres — taille de fenêtre, seuils, pondérations et règle de fusion — sont choisis uniquement sur le sous-ensemble d'apprentissage de chaque fold. Une fois le protocole arrêté et le corpus agrandi, ces paramètres sont figés et évalués une seule fois sur le test conservé à part.

4.3 Mesures et incertitude

La décision paire-à-paire est évaluée par la précision, le rappel, le F1, le taux de faux positifs et l'aire sous la courbe précision–rappel. La localisation demande une mesure séparée de recouvrement temporel. Les résultats doivent être rapportés par famille, accompagnés d'intervalles de confiance par bootstrap au niveau des familles lorsque le corpus sera assez grand.

Le classement dans un catalogue peut rester un diagnostic, mais il ne mesure pas l'objectif principal. Être classé premier parmi huit candidats ne démontre pas qu'une paire dépasse un seuil fiable face à des morceaux inconnus.

4.4 Critères de réfutation et de décision

- **Rejeter H_1** si, sur un test indépendant avec négatifs difficiles, les scores ne discriminent pas les classes au-delà de l'incertitude attendue.
- **Rejeter H_2** si les stems n'améliorent pas de façon stable le mix complet, ou si le gain disparaît sur de nouvelles familles ou un nouveau générateur.
- **Rejeter H_3** si la fusion choisie en validation accroît surtout les faux positifs ou si son gain ne se reproduit pas sur le test.
- **Réviser la représentation** si les passages les mieux notés ne recouvrent pas les passages annotés, même lorsque la décision globale est correcte.

5. État des observations du POC

Le corpus de travail comporte actuellement huit familles, chacune avec un original et un extrait généré. Les expériences ont testé une vectorisation MIDI par fenêtres, la vélocité, l'activité, les contours, la fusion de stems et un alignement local de séquences mélodiques.

Le meilleur candidat exploratoire accepte une paire si la fusion synchronisée des stems `bass` et `other`, ou l'alignement exact des intervalles vocaux, dépasse son seuil appris dans le fold. Agrégée sur les 28 choix de deux familles tenues à l'écart, cette règle produit :

0,800	0,857	0,750	7 / 56
F1	précision	rappel	faux positifs

Ces 112 décisions ne sont pas 112 observations indépendantes : chaque paire positive est réévaluée sept fois avec des ensembles d'apprentissage différents. Le résultat décrit la stabilité du pipeline sur **huit familles seulement**. Il est utile pour choisir la prochaine ablation, mais sa précision numérique ne doit pas être présentée comme la performance attendue en production.

Les résultats par famille montrent aussi une forte hétérogénéité. La fusion MIDI détecte Rasputin dans six folds sur sept ; l'ajout des intervalles vocaux récupère Brother Louie, mais peut perdre Daddy Cool selon les seuils

choisis. Cette instabilité est compatible aussi bien avec un signal réel mais fragile qu'avec un réglage trop adapté au corpus.

6. Contrôle réalisé sur le mix complet

Un chromagramme à douze classes a été calculé directement sur chaque WAV master, sans Spleeter ni Basic Pitch. Des fenêtres de dix secondes ont été comparées sous les douze transpositions et six rapports de tempo. Le score le plus robuste de cette branche impose une continuité sur deux fenêtres voisines.

Utilisé seul, ce contrôle obtient un F1 exploratoire de **0,679**, contre **0,777** pour la fusion MIDI synchronisée `bass` + `other`. Les scores chroma sont fortement comprimés et se recouvrent entre paires positives et négatives : le seuil est donc fragile. Cette comparaison ne permet pas encore d'attribuer l'écart à Spleeter, car elle change simultanément le signal d'entrée et la représentation — chroma spectral du mix d'un côté, stems puis MIDI de l'autre. Une comparaison chroma-sur-mix contre chroma-sur-stems reste nécessaire pour isoler l'effet de la séparation et tester strictement H_2.

Le chroma fournit néanmoins une information complémentaire. Une règle choisie dans chaque fold, positive si la branche `bass` + `other` **ou** le chroma continu dépasse son seuil, obtient :

0,847	0,855	0,839	8 / 56
F1	précision	rappel	faux positifs

Elle détecte Rasputin dans six folds sur sept. Le gain global vient surtout de Mambo No. 5 et Daddy Cool, mais la règle perd Brother Louie dans ces folds. L'ajout d'une troisième branche vocale réduit le F1 à 0,836 ; elle n'est donc pas retenue. La fusion à deux branches devient le meilleur candidat du POC, sans constituer une estimation finale de performance.

Une seconde ablation applique ensuite **le même chroma** au master et aux stems Spleeter. Avec la même continuité de trois fenêtres, le mix obtient un F1 de 0,660 et un taux de faux positifs de 0,268. La fusion chroma synchronisée `bass` + `other` tombe à 0,614 et 0,411. H_2 n'est donc pas soutenue pour cette représentation : la séparation dégrade le chroma au lieu de l'améliorer. Le bon résultat du pipeline MIDI dépend plutôt de la transcription symbolique, ou de son interaction avec les stems, que de la séparation seule.

7. Conclusion opérationnelle

L'hypothèse défendable n'est pas que l'on peut « retrouver les pistes d'origine » d'un master. Elle est que certaines relations musicales locales peuvent rester mesurables entre deux enregistrements transformés, et que la séparation de sources pourrait — ou non — rendre ces relations plus faciles à détecter. Le protocole est construit pour départager ces possibilités par ablation, sur des familles inédites et avec des négatifs difficiles.

À ce stade, le POC fournit un signal exploratoire, un meilleur candidat de fusion et des localisations temporelles. Il montre aussi que Spleeter n'aide pas toutes les représentations : son intérêt éventuel doit être établi pour chaque mesure. Le POC ne permet encore ni d'attribuer l'origine exacte d'un morceau généré, ni d'estimer une performance générale, ni de conclure juridiquement à un plagiat. L'étape décisive suivante est un corpus plus large, avec négatifs difficiles et test par familles conservé intact.

Références

1. Suno, « Suno — CA AB 2013 Disclosure », mise à jour du 1er janvier 2026.
2. R. Hennequin, A. Khlif, F. Voituret et M. Moussallam, « Spleeter: a fast and efficient music source separation tool with pre-trained models », *Journal of Open Source Software*, 5(50), 2154, 2020.
3. R. M. Bittner et al., « A Lightweight Instrument-Agnostic Model for Polyphonic Note Transcription and Multipitch Estimation », *ICASSP*, 2022.
4. D. P. W. Ellis et G. E. Poliner, « Identifying 'Cover Songs' with Chroma Features and Dynamic Programming Beat Tracking », *ICASSP*, 2007.